ACTE-FoG：面向冻结步态检测的踝部—协调—时序集成模型

中文期刊论文方法章节（详细版）

基于 FoG-STAR 数据集最终有效工程实现整理

步态

本文给出 ACTE-FoG（Ankle-Coordination Temporal Ensemble for Freezing of Gait Detection）的完整方法定义。该模型针对小样本、强个体差异、多部位惯性信号以及冻结步态具有短暂性和上下文依赖等特点，采用“踝部局部动力学—全身协调关系—短时序概率解码”的三级表征框架。最终分类器并非复杂深度网络，而是由 72 维可解释运动学/频谱/缺失/协调特征、500 棵极端随机树以及 7 窗口时序解码器组成。以下内容按照学术期刊 Methods 部分的规范进行描述，并与最终工程实现保持一致。

比随机森林引入更多随机数

3 方法

3.1 问题定义

冻结步态（freezing of gait，FoG）表现为行走过程中有效前进运动的短暂中断或显著减弱。从信号建模角度，可将 FoG 检测定义为多通道惯性时序信号上的二分类问题。设连续惯性观测序列为：

$$X = x_{t_{t=1}}^{N}, x_t \in \mathbb{R}^{24} \tag{1}$$

inertial measurement unit

其中，N 为时间采样点数；24 个通道来自左踝、右踝、腰背和腕部 4 个惯性测量单元（IMU），每个 IMU 包含三轴加速度和三轴角速度，共 6 个通道。对第 i 个时间窗口 X_i，目标是估计其属于 FoG 的后验概率：

$$p_i = P(y_i = 1 | X_i) \tag{2}$$

其中 y_i=1 表示 FoG，y_i=0 表示非 FoG。ACTE-FoG 的整体映射可表示为：

$$X_i - P \rightarrow \left(f_i^A \oplus f_i^C\right) - E \rightarrow p_i - T \rightarrow \tilde{p}_i \tag{3}$$

式中，P 表示预处理与特征构建；f_iˆA 为双踝局部动力学表征；f_iˆC 为全身协调表征；E 为 ExtraTrees 集成分类器；T 为短时序概率解码器；p̃_i 为最终用于判别的时序平滑概率。最终每个 2 s 窗口对应一个 72 维特征向量。

把每个窗口的分数替换为它邻近若干窗口概率的平均值

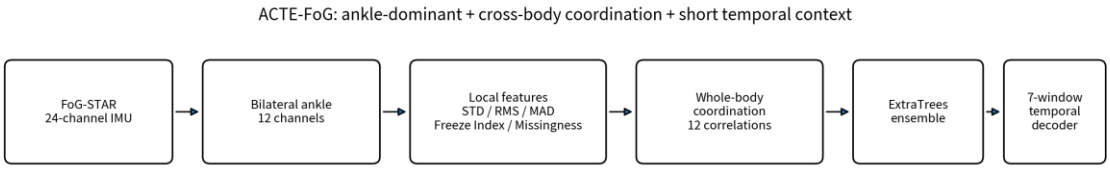


图 1 ACTE-FoG 模型总体技术路线：双踝局部动力学、全身协调关系与短时序概率解码

3.2 多部位惯性信号组织

四个 IMU 分别位于左踝、右踝、腰背和腕部。对于任一传感器位置 s，其三轴加速度和三轴角速度分别定义为：

$$a_s(t) = \left[a_{s,x}(t), a_{s,y}(t), a_{s,z}(t)\right]^{\mathrm{T}} \tag{4}$$

$$g_s(t) = \left[g_{s,x}(t), g_{s,y}(t), g_{s,z}(t)\right]^{\mathrm{T}} \tag{5}$$

传感器位置	加速度	角速度	通道数
左踝	a_x, a_y, a_z	g_x, g_y, g_z	6
右踝	a_x, a_y, a_z	g_x, g_y, g_z	6
腰背	a_x, a_y, a_z	g_x, g_y, g_z	6
腕部	a_x, a_y, a_z	g_x, g_y, g_z	6
合计	12	12	24

ACTE-FoG 并未将 24 路原始信号无约束地展开为大规模高维输入，而是显式区分“局部判别信息”和“全身协调信息”。双踝 12 路信号用于提取高分辨率时域、频域和缺失性特征；腰背与腕部信号主要通过跨部位相关性进入模型。该设计在保留全身运动关系的同时控制模型容量，适合仅包含 22 个独立受试者的临床可穿戴数据。

3.3 信号预处理与窗口构造

3.3.1 记录级滤波

所有预处理均在单个（subjectID，sessionID，taskID）记录内部独立进行，以避免跨患者、跨会话或跨任务的信号拼接。FoG-STAR 的采样频率为 60 Hz。对每一惯性通道采用四阶 Butterworth 带通滤波器，通带设置为 0.5–20 Hz，并使用二阶节（second-order sections，SOS）形式的前向—反向零相位滤波：

非因果，只能用于离线滤波

$$x^{(f)} = filtfilt(B_{0.5-20}, x) \tag{6}$$

零相位处理能够避免相位偏移对波形形态和跨通道同步关系的干扰。对于含缺失值的通道，仅对连续有效片段独立执行滤波；有效片段长度大于 30 个采样点时执行前向—反向滤波，避免极短序列造成数值不稳定。

3.3.2 时间窗口划分

滤波后的信号被划分为固定 2 s 时间窗口。由于采样率为 60 Hz，每个窗口包含 120 个采样点。窗口之间采用 75% 重叠，因此滑动步长为：

$$\mathrm{S} = 120 \times (1 - 0.75) = 30\ \text{samples} = 0.5\ \mathrm{s} \tag{7}$$

第 i 个窗口可写为：

$$X_i = x_{iS}, \ldots, x_{iS+119} \in \mathbb{R}^{120\times 24} \tag{8}$$

因此系统每 0.5 s 产生一次新的 FoG 概率估计。2 s 窗口与 0.5 s 步长既保留局部冻结相关振荡，又使相邻窗口具有足够的时间分辨率用于短时序建模。

3.3.3 窗口内去均值

对每个窗口、每个通道独立计算有效样本均值并进行中心化。设 Ω_{i,c} 为窗口 i 中通道 c 的有效采样集合，则：

$$\mu_{i,c} = \left(1/\left|\Omega_{i,c}\right|\right)\Sigma_{t\in\Omega_{i,c}} x_{i,t,c} \tag{9}$$

$$\hat{x}_{i,t,c} = x_{i,t,c} - \mu_{i,c} \tag{10}$$

逐窗口中心化可降低传感器静态偏置、穿戴姿态差异和低频基线漂移，同时保留与步态节律、震颤和冻结相关的动态波动。

3.3.4 缺失数据编码

FoG-STAR 部分惯性通道存在缺失值。ACTE-FoG 不将缺失值仅视为需要插补的噪声，而是显式记录其缺失比例。对通道 c 定义窗口缺失率：

$$M_{i,c} = 1 - \left[\Sigma_{t=1}^{L} I\left(x_{i,t,c}\text{有效}\right)\right]/L \tag{11}$$

窗口中心化后，缺失样本用 0 代替。由于 0 在中心化空间中对应局部均值，该处理比在原始空间直接补 0 引入的人工幅值更小。同时，M_{i,c} 被作为独立特征保留，使分类器能够区分“真实低幅运动”和“由于通道缺失导致的低幅表示”。

3.3.5 窗口标签生成

原始 FoG 标签位于采样点级。对每个 2 s 窗口采用多数投票生成窗口标签：

$$y_i = mode{y_{i,1}, \ldots, y_{i,120}} \tag{12}$$

当 FoG 标记在窗口内占多数时，该窗口被标记为 FoG。活动类型（如 walk、turn-left、turn-right、stand）仅用于分层误差分析和可选 hard-negative 训练，不作为最终模型的推理输入，从而避免部署时对外部活动标签的依赖。

3.4 双踝主导的局部动力学表征

实验探索表明，踝部惯性信号是 FoG-STAR 中最稳定的局部判别来源。ACTE-FoG 因此以左、右踝的 12 路 Acc/Gyro 信号作为主要局部表征。对每个通道计算标准差、均方根、平均绝对一阶差分、冻结指数和缺失比例 5 类特征。12 个通道共得到 60 维双踝表示。

3.4.1 运动波动强度

$$\sigma_c = sqrt\left[(1/L)\Sigma_{t=1}^{L} \hat{x}_{t,c}{}^2\right] \tag{13}$$

标准差反映 2 s 窗口内运动的总体波动程度。FoG 发生时，周期性下肢运动减弱、局部高频震颤增强或运动幅值突然变化，均可导致该统计量发生改变。双踝 12 个通道对应 12 维标准差特征。

3.4.2 均方根运动能量

$$R_c = sqrt\left[(1/L)\Sigma_{t=1}^{L} \hat{x}_{t,c}{}^2\right] \tag{14}$$

与标准差值相同

均方根用于量化窗口内信号能量。经过严格去均值后，RMS 与标准差在理论上高度相关，但在含缺失、有限精度和预处理边界条件下二者并非完全重合。考虑到 ExtraTrees 能够自动选择有效变量，本研究保留二者作为独立候选表征。

3.4.3 平均绝对一阶差分

$$D_c = [1/(L-1)]\Sigma_{t=2}^{L} \left|\hat{x}_{t,c} - \hat{x}_{t-1,c}\right| \tag{15}$$

D_c 描述相邻采样点之间的平均变化幅度，对高频振荡、信号粗糙度和不规则快速变化敏感。与标准差和 RMS 相比，该特征更强调局部动态变化速度。

3.5 冻结相关频谱表征

冻结步态通常伴随运动频谱能量从正常步态节律频段向更高频段重新分布。ACTE-FoG 因此对每个双踝通道计算冻结相关频谱比值。对于中心化信号，其离散傅里叶变换和功率谱分别为：

$$X_c(f) = FFT\hat{x}_{1,c}, \ldots, \hat{x}_{L,c} \tag{16}$$

$$P_c(f) = |X_c(f)|^2 \tag{17}$$

由于 L=120、f_s=60 Hz，频率分辨率为 0.5 Hz。定义正常运动主频带和冻结相关频带分别为：

$$F_L = [0.5,3)Hz, F_F = [3,8)Hz \tag{18}$$

$$P_{L,c} = \Sigma_{f \in F_L} P_c(f), P_{F,c} = \Sigma_{f \in F_F} P_c(f) \tag{19}$$

最终冻结指数定义为：

$$FI_c = log\left[1 + P_{F,c}/\left(P_{L,c} + \varepsilon\right)\right], \varepsilon = 10^{-6} \tag{20}$$

对比直接使用能量比，log(1+•) 变换能够压缩异常大的频谱比值，降低少数极端频点对树模型分裂的影响。12 个双踝通道对应 12 维 FI 特征。

3.6 显式缺失性表征

对双踝 12 个通道分别保留式（11）定义的缺失比例 M_c。因此双踝局部表示可写为：

$$f_i^A = [\sigma, R, D, FI, M] \in \mathbb{R}^{60} \tag{21}$$

其维度构成为 12_σ + 12_R + 12_D + 12_FI + 12_M = 60。该设计将运动学变化、频谱异常和传感器可靠性统一编码到同一窗口级表征中。

3.7 全身协调关系表征

FoG 不仅表现为局部足部运动异常，还可能伴随下肢、躯干和上肢之间运动耦合关系的改变。ACTE-FoG 将 4 个传感器位置视为 4 个运动节点：

$$V = L, R, B, W \tag{22}$$

其中 L、R、B、W 分别表示左踝、右踝、腰背和腕部。对每个节点，先计算三轴加速度和三轴角速度的向量模：

$$m_s^a(t) = sqrt\left[\hat{a}_{s,x}{}^2(t) + \hat{a}_{s,y}{}^2(t) + \hat{a}_{s,z}{}^2(t)\right] \tag{23}$$

旋转不变性，保留随时间变化的强度序列

$$m_s^g(t) = sqrt\left[\hat{g}_{s,x}{}^2(t) + \hat{g}_{s,y}{}^2(t) + \hat{g}_{s,z}{}^2(t)\right] \tag{24}$$

对任意两个身体部位 s_i 和 s_j，分别计算加速度模和角速度模之间的 Pearson 相关系数：

上下肢和躯干动作是否同步

$$\rho_{s_i,s_j}^q = corr\left(m_{s_i}^q, m_{s_j}^q\right), q \in a, g \tag{25}$$

四个节点共有 C(4,2)=6 个唯一组合：L－R、L－B、L－W、R－B、R－W 和 B－W。加速度产生 6 个相关特征，角速度产生 6 个相关特征，因此：

$$f_i^C = [\rho^a, \rho^g] \in \mathbb{R}^{12} \tag{26}$$

若某一窗口因通道恒定或完全缺失导致相关系数无法定义，则将其置为 0。该 12 维向量可以看作一个窗口特异的“运动协调图”边权集合：4 个身体部位为节点，相关系数为边。与显式图神经网络相比，该表示在小样本条件下参数更少、可解释性更强。

3.8 最终 72 维特征向量

工程实现中，特征生成器首先对全部 24 个通道计算 5 类通道特征，共 120 维，并额外构造 12 维全身相关性，中间表示共 132 维。随后最终特征选择器仅保留双踝 12 通道对应的 60 维局部特征以及全部 12 维全身协调特征。因此最终分类器输入为：

$$f_i = [f_i\hat{}A, f_i\hat{}C] \in \mathbb{R}\hat{}\{72\} \tag{27}$$

模块	特征定义	维度
双踝运动波动	标准差 σ	12
双踝运动能量	RMS	12
双踝局部变化	平均绝对一阶差分 D	12
双踝冻结频谱	冻结指数 FI	12
双踝可靠性	缺失比例 M	12
全身加速度协调	6 个身体部位对相关系数	6
全身角速度协调	6 个身体部位对相关系数	6
总计	—	72

该结构形成“高分辨率下肢局部动力学 + 低维全身协调摘要”的层级表示。其目的并非减少传感器使用，而是限制与 FoG 判别关系较弱的高维自由度，降低患者数量有限时的过拟合风险。

3.9 ExtraTrees 集成分类器

最终窗口级分类器采用 Extremely Randomized Trees（ExtraTrees）。设森林包含 B 棵决策树：

$$E = h_1, h_2, \ldots, h_B \tag{28}$$

本研究设置 B=500。对窗口特征 f_i，第 b 棵树输出 FoG 概率 p_iˆ(b)，森林输出为各树概率均值：

p_i = (1/B) Σ_{b=1}^{B} p_i^(b) (29)

参数	最终设置	作用
n_estimators	500	降低单树方差，提高集成稳定性
criterion	Gini	节点划分不纯度指标
min_samples_leaf	3	限制过度细分，提高跨患者泛化
max_features	0.5	每次分裂随机使用约 36/72 个候选特征
class_weight	balanced	自动平衡 FoG/非 FoG 类别
bootstrap	False	使用 ExtraTrees 原生随机阈值机制
max_depth	None	不显式限制深度，由叶节点约束控制复杂度

对于类别 c∈{0,1}，balanced 类权重可写为：

$$w_c = N/(2N_c) \quad (30)$$

其中 N 为训练窗口总数，N_c 为类别 c 的样本数。该权重提高少数 FoG 窗口对树分裂的贡献。ExtraTrees 能够自然学习非线性阈值、特征交互和不同特征子集之间的组合关系，同时不需要深度神经网络所需的大规模独立受试者样本。

3.10 短时序概率解码

单独对每个 2 s 窗口分类会忽略 FoG 的持续性和上下文依赖。ACTE-FoG 因此不在原始信号层叠加大型时序网络，而是在概率层进行短时序解码。离线中心化解码器使用 K=7 个相邻窗口。由于窗口中心间隔为 0.5 s，7 个窗口中心跨越约 3 s；考虑每个窗口自身覆盖 2 s 原始信号，最终一次预测所涉及的原始观测联合覆盖约 5 s。

$$\tilde{p}_i = (1/|N_i|)\Sigma_{j\in N_i} p_j \quad (31)$$

$$N_i = i-3, \ldots, i+3 \quad (32)$$

时序平均只在同一受试者、同一任务连续序列内部执行，不跨任务拼接。位于序列边缘的窗口使用实际存在的邻域窗口数量作为分母。该解码器能够抑制孤立概率尖峰、增强持续 FoG 证据，并将短暂的前 FoG—FoG—后 FoG 运动状态纳入统一判断。

3.11 在线因果时序解码

中心化 7 窗口解码需要访问未来窗口，适用于离线评估。为支持在线检测，工程同时实现因果版本：

$$\tilde{p}_i^{(causal)} = (1/K_i)\Sigma_{j=max(1,i-K+1)}^{i} p_j \quad (33)$$

其中 K=7，K_i 为当前可获得的历史窗口数。该版本仅依赖当前及过去窗口，不使用未来数据，因此可用于持续在线推理。其有效历史运动上下文同样约为 5 s。主论文离线性能采用中心化解码器，实时部署实验应单独报告因果解码结果。

3.12 二分类阈值选择

对于需要输出二值 FoG 标签的指标，阈值只依据验证集确定。定义阈值 τ 下的敏感度和特异度分别为：

$$Sens(\tau) = TP(\tau)/[TP(\tau) + FN(\tau)] \quad (34)$$

$$Spec(\tau) = TN(\tau)/[TN(\tau) + FP(\tau)] \quad (35)$$

最终阈值选择为：

$$\tau* = argmin_{\tau\in[0,1]}|Sens(\tau) - Spec(\tau)| \quad (36)$$

在roc上与对角线相交

工程在 0–1 区间以 0.001 为步长搜索阈值。测试集标签不参与 τ* 的选择。AUROC 和 AUPRC 直接基于连续概率 p̃_i 计算，与该阈值无关；F1、Sensitivity、Specificity 和 Accuracy 则使用验证集得到的 τ*。

3.13 固定患者独立训练—验证—测试协议

为与 FoG-STAR 原始研究的患者独立评估口径保持一致，最终固定划分采用 11/5/6 个受试者：

$$D_train = 1, \ldots, 11 \quad (37)$$

$$D_val = 12, \ldots, 16 \quad (38)$$

$$D_test = 17, \ldots, 22 \quad (39)$$

患者划分在窗口构造和模型拟合之前确定。同一患者产生的全部窗口只能属于一个数据子集，从而避免高重叠窗口导致患者级信息泄漏。分类器仅在训练患者窗口上拟合，验证患者用于阈值选择和模型分析，测试患者只用于最终固定协议评价。

固定划分实验采用 5 个随机种子重复训练，并以均值±标准差报告性能。当前最终模型在该协议下测试 AUROC 为 0.9318±0.0003，说明在这一固定测试组上模型能够达到约 0.93 的判别水平；但该结果应与后述 LOSO 患者级确认性评价同时呈现。

3.14 患者级留一法（LOSO）确认性评价

固定测试集性能可能受到患者组成影响。为检验跨患者泛化稳定性，进一步采用 leave-one-subject-out（LOSO）评估。对第 s 个患者：

$$D_test^{(s)} = s, D_train^{(s)} = D\ s \quad (40)$$

每一折重新训练独立 ExtraTrees 模型，严格保证被留出的患者没有任何窗口进入训练。22 折预测合并后计算 pooled AUROC/AUPRC：

$$AUROC_pooled = AUROC(y_{1:22}, p_{1:22}) \quad (41)$$

同时，对同时包含 FoG 与非 FoG 窗口的患者分别计算 AUROC_s，并得到 subject-macro AUROC：

$$AUROC_macro = (1/|S*|)\Sigma_{s\in S*} AUROC_s \quad (42)$$

部分受试者完全没有 FoG 阳性窗口，因此单患者 AUROC 在数学上不可定义。这些患者仍参与 pooled 指标，但不进入 subject-macro AUROC 的算术平均。当前 LOSO pooled AUROC 约为 0.908，subject-macro AUROC 约为 0.888，说明固定 11/5/6 结果具有一定 split sensitivity，LOSO 应作为更严格的跨患者泛化证据。

leave-one-subject-out

3.15 可选的 hard-negative 加权策略

活动分层误差分析发现，Standing 和 Turning 是主要假阳性来源。为验证训练阶段是否可通过难负样本强调改善该问题，工程实现了可选 sample weighting。对非 FoG 窗口：

$$w_i = 2.0, activity = Standing \quad (43)$$

$$w_i = 1.5, activity \in Turn - left, Turn - right \quad (44)$$

$$w_i = 1.0, 其他情况；FoG阳性窗口保持 w_i = 1.0 \quad (45)$$

活动标签仅在训练阶段用于产生样本权重，推理阶段完全不需要活动标签。确认性分析表明，该策略对整体 pooled/macro 指标和部分转向场景有轻微改善，但 Standing AUROC 未稳定提高，因此不作为 ACTE-FoG 的核心结构，仅保留为可选训练策略。

3.16 完整推理流程

对于一个此前未见的新患者，连续 24 路 IMU 信号首先按记录独立执行 0.5–20 Hz 零相位带通滤波。系统每 0.5 s 取最近 2 s、共 120 个采样点构成窗口；随后执行窗口内中心化和缺失编码。特征构建器输出 60 维双踝时域/频域/缺失特征与 12 维全身协调特征，共 72 维。ExtraTrees 输出窗口级概率 p_i，时序解码器得到 $\tilde{p}$_i，最后按照验证集阈值 τ* 输出二值状态：

$$\hat{y}_i = I(\tilde{p}_i \geq \tau*) \quad (46)$$

完整推理函数可概括为：

$$X_i^{120\times 24} \to f_i^{72} \to p_i \to \tilde{p}_i \to \hat{y}_i \quad (47)$$

3.17 模型设计依据与方法学特点

ACTE-FoG 的核心并非依赖更大的模型规模，而是针对 FoG-STAR 的数据结构建立分层约束。第一层以双踝为主，保留与冻结直接相关的下肢局部振荡、能量和频谱信息；第二层利用四个身体部位之间的 12 条协调边描述分布式运动耦合；第三层在概率层整合约 5 s 短时上下文，表达 FoG 的持续和状态转换。

$$\text{ACTE-FoG} = \text{踝部局部动力学} + \text{全身协调关系} + \text{短时序上下文} \tag{48}$$

该结构特别适用于独立患者数量有限的临床可穿戴数据。与将 24 路信号直接输入大型 Transformer、Mamba 或图神经网络相比，ACTE-FoG 的训练自由度更低，特征含义更明确，并能通过消融实验直接验证每个信息层级的价值。

3.18 与单踝 1D-CNN 基线的区别

公开 1D-CNN 基线以单个踝部三轴陀螺仪为输入，其窗口维度为 120×3，通过因果一维卷积直接学习局部波形表示。ACTE-FoG 在保持 2 s 窗口和患者独立评估基本口径一致的前提下，引入三个层面的扩展：①由单踝三轴 Gyro 扩展到双踝 Acc+Gyro 的局部动力学；②由单部位局部信号扩展到四部位跨节点协调关系；③由单窗口独立判别扩展到相邻窗口概率时序解码。

$$\text{1D-CNN：单部位局部波形} \rightarrow \text{FoG 概率} \tag{49}$$

$$\text{ACTE-FoG：双踝局部动力学} + \text{全身协调} + \text{短时序演化} \rightarrow \text{FoG 概率} \tag{50}$$

这种差异使 ACTE-FoG 的创新点可以通过严格消融而不是通过模型规模进行论证。

3.19 推荐消融实验设计

为验证各技术模块的独立贡献，建议在完全相同的患者级划分和评测流程下设置以下递进模型：

模型	配置	目的
M0	单踝 1D-CNN / 单踝基线	建立公开强基线
M1	双踝局部时域动力学	验证双侧下肢信息增益
M2	M1 + 冻结频谱 FI	验证冻结相关频谱表征
M3	M2 + 缺失比例 M	验证缺失感知的贡献
M4	M3 + 全身协调 ρ	验证跨部位协调信息
M5	M4 + 7 窗口时序解码	验证短时上下文贡献

其中 M3→M4 的增益直接量化“全身协调信息”在双踝局部特征之上的附加价值；M4→M5 的增益量化概率级短时序上下文的价值。该设计与 ACTE-FoG 的结构一一对应，能够避免将多个模块一次性组合后无法判断性能来源的问题。

3.20 ACTE-FoG 的最终数学定义

综合上述模块，最终模型可表示为：

$$\tilde{p}_i = T_7 E_{500}\left[f_i^A \oplus f_i^C\right] \tag{51}$$

其中，f_iˆA∈ℝˆ60 为双踝局部运动学、频谱和缺失表征；f_iˆC∈ℝˆ12 为全身加速度/角速度协调表征；E_500 表示包含 500 棵树的平衡 ExtraTrees 分类器；T_7 表示 7 窗口短时序概率解码。

$$X_i^{120\times 24} \rightarrow f_i^{72} \rightarrow ExtraTrees_{500} \rightarrow p_i \rightarrow T_7 \rightarrow \tilde{p}_i \tag{52}$$

因此，ACTE-FoG 不是单纯增加传感器数量或模型参数，而是将 FoG 分解为三个互补尺度：局部下肢动力学、分布式身体协调和短时运动状态演化。在 FoG-STAR 这类患者数量有限、窗口数量较多的数据条件下，该方法兼顾判别性能、可解释性和跨患者验证的可实施性。

3.21 论文结果报告时的统计口径

为了保证方法评价的严谨性，固定 11/5/6 划分和 LOSO 应在论文中承担不同作用。固定划分用于与原研究和既有基线直接比较；当前 ACTE-FoG 在该协议下 5 个随机种子的测试 AUROC 为 0.9318±0.0003。LOSO 用于评估患者组成变化下的泛化稳定性；当前 pooled AUROC 约为 0.908。由于模型探索阶段已经多次观察固定测试集结果，论文主结论不宜仅依据 0.9318，应同时报告 LOSO 结果和活动分层结果，以避免高估模型对未知患者的普适性能。